

Geração de Trajetórias

De logs de GPS a inferência espacial: construção de trajetórias e mobilidade urbana

Autores:

Arthur Chavarri do Coutto

Emanuel Marcílio Castelo Severo

Maria Eduarda Marques de Araújo

Maria Vitória da Silva Vieira

Pedro Henrique Peixoto do Amaral

O Contexto e o Problema

Por que os dados de mobilidade urbana precisam de tratamento prévio intensivo antes de alimentar modelos de inteligência artificial?

Contexto

- ▶ Dados GPS são essenciais para análise de mobilidade urbana.
- ▶ Frotas de ônibus produzem milhões de registros de localização.
- ▶ Falhas de sinal geram registros incompletos e inconsistentes.


Problema

Perda de sinal GPS
↓
Saltos entre coordenadas distantes
↓
Rotas sintéticas irreais
↓
Baixa qualidade dos modelos preditivos

Criar um pipeline de pré-processamento capaz de reduzir os efeitos dessas falhas antes da geração de trajetórias sintéticas.

O Desafio dos Dados Brutos de GPS

- ▶ O monitoramento de frotas gera dados vitais para simulações, porém falhos.
- ▶ Suscetibilidade a intempéries, áreas de sombra e túneis criam lacunas graves.
- ▶ O Pulo do GPS: Conexões euclidianas sobre dados faltantes geram rotas impossíveis (ex: travessia da Baía de trajetórias ruidosas para treinar modelos
- ▶ preditivos resulta em caminhos sintéticos fisicamente inviáveis.



Objetivos do Projeto



Pré-processamento (R)

Construir um pipeline para limpeza
algorítmica e quebra geométrica
de trajetos ruidosos.



Geração (Python)

Adaptar o gerador estatístico
PaLMTo-Gen para aprender
padrões em rotas urbanas longas.



Validação Visual

Atestar a qualidade dos caminhos
sintéticos via visualizações de
dados geoespaciais interativas.

Modelagem Probabilística

1. Discretização da Malha

A modelagem requer a transição de coordenadas contínuas para espaços discretizados. A malha urbana do Rio de Janeiro foi subdividida em um grid celular

2. Lógica de Linguagem

Cada célula atua como um "token".
O modelo calcula probabilidades usando N-grams para prever a transição de uma célula a outra, simulando o histórico da frota.

Fase 1: Tratamento em R

- ▶ **Limiar de Tempo:** Implementação de uma heurística rigorosa
- ▶ **Regra de Negócio:** Se a diferença entre sinais exceder 3 minutos, a viagem é encerrada.
- ▶ **Sub-viagens:** Quando o sinal retorna, cria-se uma nova identificação.
- ▶ **Benefício:** Impede que o modelo em Python extraia "pontes" espaciais inexistentes na fase de treinamento.



Fase 2: Geração com PaLMTo-Gen




Configuração Espacial

O motor em Python operou sobre um grid balanceado para capturar interseções sem perder a resolução da avenida.

Adicionou-se tratamento de exceções para ignorar sub-viagens residuais de um único ponto, prevenindo falhas de tensores durante o processamento espacial e o emparelhamento com o sistema Folium.


Avaliação Experimental

- ▶ **Validação:** 10.000 rotas geradas (linha 328) renderizadas em mapas topológicos.
- ▶ **Eficácia Comprovada:** O algoritmo de corte em R eliminou com sucesso a travessia impossível pela Baía de Guanabara.
- ▶ **Aderência:** O gerador acompanhou rodovias marginais baseando-se apenas nos trigramas, sem conhecimento offline.
- ▶ **Ameaça:** A esparsidade em linhas de baixo volume dificulta o aprendizado do motor probabilístico.



Trabalhos Futuros

Trabalhos Futuros Sistema Inteligente de Rotas Evoluir o protótipo para uma plataforma de navegação urbana que utilize o algoritmo de predição de rotas para estimar trajetos prováveis a partir de padrões históricos e telemetria em tempo real.



A integração com técnicas de map matching (OSRM/OSMnx) garantiria aderência à malha viária oficial e maior precisão operacional.

Conclusão

Integridade Sequencial A qualidade da geração sintética está diretamente atrelada à limpeza prévia da telemetria bruta. O filtro de tempo validou-se como essencial.

Limitações do Grid Apesar do ganho topológico, a técnica de “grid centroid” ocasionalmente afasta o desenho da rota sintética das exatas guias pavimentadas oficiais.

Obrigado!

Referências:

- WAZLAWICK, Raul. Metodologia de Pesquisa para Ciência da Computação. Elsevier Brasil, 2017.
- ZOBEL, Justin. Writing for Computer Science. Springer, 2015.
- OGASAWARA et al. Dataset on Bus Mobility and Environmental Indicators from Rio de Janeiro. Nature, 2025.
- HAYAT; MARIO. Effective Trajectory Imputation using Simple Probabilistic Language Models. IEEE, 2024.