

Geração de Trajetórias Sintéticas de Transporte Público: Otimização e Limpeza de Dados de GPS com PaLMTo-Gen

Arthur Chavarri do Coutto
Emanuel Marcílio Castelo Severo
Maria Eduarda Marques de Araújo
Maria Vitória da Silva Vieira
Pedro Henrique Peixoto do Amaral

¹Centro Federal de Educação Tecnológica Celso Suckow da Fonseca - CEFET/RJ

{arthur.coutto, emanuel.severo, maria.araujo,
maria.vieira, pedro.amaral}@aluno.cefet-rj.br

Resumo. O monitoramento de frotas de transporte público via GPS gera dados essenciais para simulações urbanas e planejamento de mobilidade. No entanto, perdas de sinal e ruídos de hardware frequentemente comprometem a qualidade dessas trajetórias. Este trabalho apresenta uma metodologia integrada para a limpeza de dados e geração de trajetórias sintéticas utilizando a ferramenta de modelagem probabilística PaLMTo-Gen. Propõe-se um algoritmo de pré-processamento em linguagem R que identifica e segmenta pulos temporais em sub-viagens, impedindo a geração de rotas fisicamente inviáveis. Os resultados, validados qualitativamente através de mapas interativos, demonstram a eficácia da abordagem na criação de dados sintéticos consistentes e fiéis à malha viária urbana.

1. Introdução

A análise de mobilidade urbana contemporânea depende fortemente de dados de geolocalização coletados em tempo real. O monitoramento via GPS de frotas de ônibus gera um volume massivo de informações, permitindo a identificação de gargalos, planejamento de rotas e simulações de tráfego. Contudo, a coleta em campo é suscetível a intempéries, áreas de sombra de sinal e túneis, resultando em conjuntos de dados com lacunas significativas. A utilização de dados brutos para o treinamento de modelos preditivos frequentemente leva à geração de rotas irreais, exigindo técnicas robustas de engenharia de dados antes da etapa de modelagem.

O problema central abordado neste trabalho surgiu com a possibilidade de usar uma base de dados com Logs de GPS dos ônibus da cidade do Rio de Janeiro. A base contém logs com atributos como *Timestamp*, *Distance*, *Longitude*, *Latitude*, *Velocity*, entre outros, e faz-se necessário um tratamento prévio para seu uso. O objetivo seria usar os dados no modelo de geração de trajetórias desenvolvido por Mohammed and Nascimento [2024]. Na implementação, mesmo com uma série de tratamentos iniciais que buscaram eliminar logs incorretos, ônibus parados, entre outros problemas, foi encontrada uma anomalia nas trajetórias geradas, que mostravam "pulos" de GPS no modelo de síntese de trajetórias. Quando um veículo perde o sinal em um ponto e o recupera quilômetros depois, os algoritmos tradicionais tendem a conectar essas coordenadas por meio de distâncias Euclidianas. Em contextos geográficos complexos, como o Rio de Janeiro, isso

resulta em rotas que cruzam corpos d'água ou áreas inacessíveis. Dessa forma, torna-se imprescindível estabelecer um método de tratamento que impeça o algoritmo de interpretar saltos temporais como deslocamentos válidos.

O objetivo geral deste projeto é desenvolver um fluxo de trabalho que gere trajetórias sintéticas urbanas realistas, contornando as falhas inerentes ao rastreamento por GPS. Para alcançar essa meta, estabeleceram-se três objetivos específicos. O primeiro é construir um *pipeline* de pré-processamento em R para limpeza e quebra de trajetos ruidosos. O segundo consiste em adaptar e aplicar o gerador PaLMTo-Gen, baseado em Python, para aprender padrões espaciais em rotas longas. Por fim, o terceiro objetivo é validar os caminhos gerados através de visualizações interativas de dados geoespaciais.

A estrutura deste artigo reflete as etapas do *pipeline* desenvolvido. A Seção 2 explora os conceitos de modelagem probabilística de trajetórias e métricas espaciais. A Seção 3 aborda o estado da arte na área. A Seção 4 detalha a arquitetura da solução, desde a segmentação em R até a geração em Python. Na Seção 5, os resultados são comparados visualmente. Por fim, a Seção 6 sintetiza os achados e sugere direções para trabalhos futuros.

2. Fundamentação Teórica

A modelagem de trajetórias sintéticas requer a compreensão da transição de coordenadas contínuas para espaços discretizados. Para que um algoritmo de linguagem aprenda um trajeto, a malha urbana é comumente subdividida em um *grid* celular. Cada célula atua como um *token* (ou palavra), e uma viagem completa é interpretada como uma sentença (sequência de *tokens*). O modelo de linguagem, através da extração de *N-grams* (como trigramas), calcula a probabilidade de transição de uma célula para outra com base no histórico de movimentação da frota.

Durante o processo de geração e conexão de pontos (origem e destino), métricas espaciais são adotadas para garantir a coesão da rota. Quando o modelo probabilístico precisa decidir o próximo passo, ele busca minimizar a distância espacial entre os candidatos e o alvo. A Equação 1 ilustra a distância Euclidiana padrão utilizada pelo algoritmo de busca para avaliar a proximidade entre dois pontos geométricos p_1 e p_2 .

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \quad (1)$$

A qualidade dos dados que alimentam essa equação dita o sucesso do modelo. A Tabela 1 exibe o formato padronizado de extração das coordenadas para o funcionamento do motor de *N-grams*, demonstrando as colunas essenciais retidas após o pré-processamento. A representação visual das sequências de coordenadas sobrepostas à cartografia real (Figura ??) permite atestar qualitativamente se o modelo respeitou a topologia física das vias originais.

3. Trabalhos Relacionados

A geração de dados sintéticos de mobilidade tem sido abordada sob diferentes perspectivas metodológicas. Modelos baseados em Cadeias de Markov de ordem variável se destacam na predição de rotas, tratando a movimentação urbana como um processo estocástico. Outros trabalhos focam estritamente no processamento de trajetórias ruidosas

Tabela 1. Estrutura de entrada do modelo espacial

ID (Trip)	Timestamp	Coordenadas (x, y)
B10098_0	2023-03-01 01:43	[-43.189, -22.904]
B10098_0	2023-03-01 01:44	[-43.190, -22.905]
B10098_1	2023-03-01 01:50	[-43.201, -22.908]

por meio de algoritmos de *Map Matching*, que forçam os sinais de satélite dispersos a se ancorarem à malha viária oficial (e.g., OpenStreetMap). O presente trabalho se diferencia ao focar no passo anterior a esses métodos espaciais: a intervenção direta no domínio temporal dos dados, criando uma heurística de particionamento que imuniza os geradores de N-gram contra falsas transições topológicas.

O código original do projeto *PaLMTo-Gen*¹ buscava criar trajetórias sintéticas em um cenário com uma pequena amostra de dados próximas ao original. Como contamos com uma larga base de dados proporcionada pela pesquisa pesquisa de Almeida et al. [2025], nossa abordagem se diferencia, e o código precisou de modificações visando gerar rotas probabilísticas segundo as rotas de ônibus e visualização na geografia da cidade do Rio de Janeiro, como ajustes do grid e geração de rotas mais extensas.

4. Método

A arquitetura da solução proposta é dividida em três fases tecnológicas: o pré-processamento estatístico e limpeza de dados utilizando a linguagem R, seguido pela modelagem e geração espacial em Python, e por fim sua visualização geoespacial de forma interativa. O objeto de estudo foi um recorte de dados contendo registros reais de ônibus urbanos na cidade do Rio de Janeiro (especificamente a linha 328), analisando-se o comportamento de veículos ao longo de um dia inteiro de operação.

A etapa de modelagem e estruturação no R teve como foco a eliminação de ruídos e a quebra de trajetos inválidos. Em uma primeira tentativa de solução, foi tentado eliminar sequencias de logs que demonstrassem que o ônibus não se movimentava, ruídos, ônibus com comportamentos incomuns². Após tratamentos iniciais, identificou-se que áreas de travessia e infraestruturas complexas interrompiam a emissão do GPS, além de logs com passagens temporais longas³. Para corrigir o erro de deslocamento sobre corpos hídricos, como mostrado na figura 1, implementou-se um algoritmo de limiar de tempo. A regra de negócio estipula que, se a diferença de *timestamp* entre dois sinais consecutivos exceder três minutos, a viagem atual é encerrada computacionalmente. Quando o sinal retorna, uma nova identificação (*sub-viagem*) é criada. Esse rigoroso enquadramento

¹<https://github.com/HayatSultan/PaLMTo-Gen>

²Os ônibus são identificados por ID e por linha, muitos logs indicavam ônibus que ficavam na linha por poucos minutos, ou com uma trajetória improvável. Tal comportamento diferia dos demais ônibus da linha.

³Originalmente, os logs são produzidos de 30 em 30 segundos. Foram encontrados períodos com logs de hora em hora e espaçamentos ainda maiores.

lógico impede que o modelo em Python extraia "pontes" espaciais inexistentes na fase de treinamento. Os dados são então encapsulados e exportados no formato *Pickle* (.pkl) utilizando o pacote *Reticulate*.




Figura 1. Exemplo de trajetórias com percursos impossíveis




Figura 2. Exemplo de trajetória interrompida precocemente

A fase de geração e plotagem foi construída sobre o motor PaLMTo-Gen no ambiente Python. A estrutura geométrica da área foi dividida por um *grid* regular ajustado estrategicamente para um *cell size* entre 100 e 150 metros. Essa dimensão foi selecionada visando equilibrar a captura de interseções viárias reais com a resolução exata da avenida. Adicionalmente, implementou-se tratamento de exceções no script original para ignorar sub-viagens residuais compostas por um único registro georreferenciado, evitando interrupções drásticas causadas por tensores vazios durante o emparelhamento com o sistema interativo Folium. A expansão do limite dinâmico de sentenças (*sentence length*) garantiu que percursos urbanos de longas distâncias atingissem seus devidos destinos sem amputações precoces, como mostrado na figura 2.

5. Avaliação Experimental

A avaliação do modelo deu-se através de observação de mapas topológicos renderizados de forma independente. O roteiro metodológico testou a capacidade do algoritmo gerador de acompanhar as rodovias marginais e complexos viários baseando-se apenas nos trigramas espaciais aprendidos, abdicando de conhecimento prévio do mapa *offline*.

Visualmente, constatou-se que a abordagem estrita de corte de anomalias no pré-processamento foi eficaz em neutralizar o artefato que permitia a travessia impossível pela Baía de Guanabara, como demonstra a figura 3. O pareamento visual de 10.000 rotas geradas demonstrou forte aderência à área percorrida pelos ônibus originais, considerando a margem de erro do GPS e a centralidade do grid executado. Na imagem também é possível ver a implementação da seleção de rotas, que podem aparecer e desaparecer se selecionadas.




Figura 3. Visualização de rotas possíveis para um caminho. Todas as rotas são possíveis e acompanham ruas e estradas das rotas pretendidas.

Como ameaça à validade do estudo, destaca-se que rotas originais compostas por baixíssimo volume de viagens diárias geram esparsidade no aprendizado. Isso impede que o motor probabilístico encontre interseções suficientes para concluir o percurso estocástico, justificando a necessidade intrínseca da escolha de frotas com alto tráfego (dados de um dia inteiro) para treinar modelos baseados em transições celulares espaciais.

6. Conclusão

Este trabalho demonstrou que a qualidade de geração de rotas sintéticas está essencialmente atrelada à integridade sequencial dos dados de origem. O objetivo principal foi alcançado com sucesso através da construção de um *pipeline* coeso que neutraliza falhas de telemetria previamente à submissão dos *tokens* aos geradores estatísticos. A segmentação por intervalo máximo de sinal validou-se como um filtro leve e essencial na correção das falsas topologias marítimas.

Apesar do ganho qualitativo robusto na estruturação do percurso, o pareamento das linhas geradas pela técnica de *grid centroid* ocasionalmente afasta visualmente o limite azul das exatas guias pavimentadas. Como trabalhos futuros, propõe-se a integração de algoritmos determinísticos de *Map Matching* (como Open Source Routing Machine ou OSMnx) pós-geração probabilística, garantindo que os dados sintéticos não apenas imitem tendências espaciais, mas trafeguem com rigor geométrico absoluto nas artérias viárias oficiais disponíveis em repositórios cartográficos abertos. Para a criação de rotas e indicações de caminhos e baldeações, outros atributos presentes no banco de dados podem ser futuramente explorados, como a distância percorrida e velocidade, pois o tempo para concluir é essencial para a recomendação de caminhos melhores, podendo gerar respostas que evitem pontos de congestionamento e outros empecilhos frequentes.

Agradecimentos

Agradecemos ao Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ) pelo suporte acadêmico e infraestrutura para a elaboração deste estudo.

Referências

- Almeida, V. d. S. V., Ogasawara, E., Carvalho, D., and Coutinho, R. (2025). Dataset on bus mobility and environmental indicators from rio de janeiro. <https://doi.org/10.17605/OSF.IO/YPTKJ>.
- Mohammed, H. S. and Nascimento, A. M. (2024). Effective trajectory imputation using simple probabilistic language models. *IEEE*.