

# Temas de Pesquisa em Mobilidade Urbana

## Consolidação de Quatro Trabalhos Incompletos

Material consolidado para organização interna

CEFET/RJ

**Resumo** Este documento consolida quatro trabalhos incompletos sobre mobilidade urbana em uma estrutura única de temas de pesquisa. O material foi reorganizado para separar, em cada tema, a introdução, o referencial teórico, a proposta de metodologia, os resultados parciais e os códigos associados. Além disso, foi criado um capítulo inicial comum com o procedimento de ETL utilizado para obtenção e preparação do dataset base empregado pelos estudos.

## 1 Capítulo 0: ETL Comum

### 1.1 Introdução

Os quatro trabalhos compartilham a mesma base de dados de mobilidade de ônibus do Rio de Janeiro. Por isso, o processo de extração e preparação inicial foi tratado como uma etapa comum. O objetivo desse capítulo é registrar como o dataset pode ser buscado, lido e salvo para uso posterior nos experimentos.

### 1.2 Referencial

O ponto de partida do conjunto de estudos é o uso de dados abertos de mobilidade urbana, em especial registros de GPS de ônibus combinados com atributos operacionais e contextuais. A documentação deixada na pasta original aponta para a fonte pública do dataset e para um fluxo simples de leitura de arquivos Parquet seguido da persistência em `RData`.

### 1.3 Proposta de Metodologia

O fluxo comum foi organizado em duas etapas. Primeiro, um script em Python lê arquivos Parquet remotos. Em seguida, um script em R orquestra o carregamento dos cinco fragmentos do dia analisado e salva um arquivo único para os estudos subsequentes.

**Listing 1.1.** Leitura simples de arquivos Parquet em Python

```
import pandas as pd

def read_parquet(filename):
    df = pd.read_parquet(filename)
    return df
```

**Listing 1.2.** Orquestração da carga do dataset em R

```
library(reticulate)

source_python("read-parquet.py")

data <- read_parquet("https://regulus.eic.cefet-rj.br/data/mobility/G1-2023-02-21-A.parquet")
data_tmp <- read_parquet("https://regulus.eic.cefet-rj.br/data/mobility/G1-2023-02-21-B.parquet")
data <- merge(data, data_tmp)
```

## 1.4 Resultados Parciais

Como resultado parcial, essa etapa produz uma base consolidada pronta para filtragens por linha, veículo, horário, velocidade e localização. Esse ETL serve como dependência explícita para os quatro temas.

## 1.5 Códigos Associados

- `codigos/00-etl/read-parquet.py`
- `codigos/00-etl/read-parquet.R`
- `codigos/00-etl/documentacao.txt`

# 2 Tema 1: Identificação de Congestionamentos com DBSCAN

## 2.1 Introdução

Este tema investiga congestionamentos em linhas de ônibus a partir de dados de GPS, velocidade e chuva. A proposta parte do entendimento de que atrasos e retenções não aparecem apenas como eventos explícitos, mas também como padrões espaço-temporais recorrentes distribuídos pela cidade.

## 2.2 Referencial Teórico

O núcleo teórico combina três frentes. A primeira é mobilidade urbana, com foco em fluidez do transporte coletivo. A segunda é aprendizado não supervisionado, especialmente agrupamento por densidade. A terceira é o algoritmo DBSCAN, escolhido por identificar agrupamentos sem exigir a quantidade de clusters previamente definida e por lidar razoavelmente bem com ruído.

### 2.3 Proposta de Metodologia

A metodologia definida no material original segue quatro passos:

1. Conversão do timestamp para hora decimal e filtragem do horário de pico.
2. Seleção de ônibus com velocidade muito baixa e exclusão de casos de estacionamento.
3. Normalização de latitude, longitude, horário e volume de chuva.
4. Aplicação de DBSCAN para identificar agrupamentos de pontos com comportamento compatível com congestionamento.

O script principal também produz recortes por região administrativa, permitindo observar padrões no Centro, em Campo Grande e em outras áreas.

### 2.4 Resultados Parciais

Os resultados parciais do trabalho indicam que o método consegue destacar regiões com concentração de eventos de baixa velocidade no horário de pico. O relatório original aponta maior incidência em áreas como Campo Grande e Centro, mas ainda reconhece limitações importantes, sobretudo o uso de um recorte temporal curto e a dificuldade em separar congestionamento recorrente de impacto climático pontual.

### 2.5 Códigos Associados

– `codigos/tema-01-dbscan/analise-congestionamento.R`

### 2.6 Possíveis Expansões para Artigo Científico

- Ampliar a janela temporal para múltiplos dias, semanas e períodos chuvosos e não chuvosos.
- Comparar o DBSCAN com métodos alternativos, como HDBSCAN, OPTICS e abordagens supervisionadas.
- Construir uma métrica formal de severidade de congestionamento combinando velocidade, duração, localização e chuva.
- Validar os agrupamentos com fontes externas, como dados viários, notícias de trânsito ou registros oficiais.
- Explorar predição de congestionamentos a partir de séries históricas e variáveis contextuais.

## 3 Tema 2: Classificação do Sentido de Trajeto com Produto Escalar

### 3.1 Introdução

Este tema aborda a ausência do campo de direção de viagem em bases de mobilidade. O problema central é distinguir, para cada observação de GPS, se o ônibus está em trajeto de ida ou de volta, mesmo quando os dois sentidos compartilham trechos fisicamente sobrepostos.

### 3.2 Referencial Teórico

O referencial do tema é formado por dados de mobilidade urbana, georreferenciamento, cálculo geodésico e álgebra vetorial. A fórmula de Haversine é utilizada para medir proximidade entre observações e terminais, enquanto o produto escalar é empregado para comparar o deslocamento instantâneo do veículo com um vetor de referência definido pelos terminais da linha.

### 3.3 Proposta de Metodologia

A proposta metodológica foi consolidada em um pipeline computacional:

1. Definição manual de dois terminais por linha.
2. Cálculo das distâncias de cada ponto até os terminais.
3. Rotulagem da localização como próximo ao terminal A, ao terminal B ou em trânsito.
4. Cálculo do produto escalar entre o vetor de deslocamento e o vetor de referência  $A \rightarrow B$ .
5. Segmentação do trajeto com base na alternância entre terminais.
6. Classificação final do segmento por soma acumulada dos sinais direcionais.

Essa solução procura reduzir oscilações locais causadas por curvas, desvios ou pequenas inversões momentâneas de direção.

### 3.4 Resultados Parciais

Os resultados parciais mostram que a solução funciona bem para trajetos completos das linhas testadas e melhora em relação ao uso isolado do produto escalar. Ainda assim, permanecem fragilidades em cenários de garagem, inconsistência no campo de linha e escolha inadequada do buffer de proximidade.

### 3.5 Códigos Associados

- `codigos/tema-02-direcao/classify.py`
- `codigos/tema-02-direcao/cumsum.py`
- `codigos/tema-02-direcao/cumsum-tendencia.py`
- `codigos/tema-02-direcao/produto-escalar.py`
- `codigos/tema-02-direcao/read-data.R`

### 3.6 Possíveis Expansões para Artigo Científico

- Automatizar a descoberta dos terminais, reduzindo dependência de parametrização manual.
- Comparar a abordagem vetorial com modelos supervisionados e métodos probabilísticos para inferência de direção.
- Formalizar um protocolo de avaliação com rotulagem manual de amostras e métricas como acurácia, precisão e F1-score.
- Tratar explicitamente cenários de garagem, desvios operacionais e inconsistências cadastrais da linha.
- Escalar o método para um conjunto maior de linhas e testar sua robustez em trajetos com maior sobreposição espacial.

## 4 Tema 3: Detecção de Anomalias em Séries Temporais de Velocidade

### 4.1 Introdução

Este tema trata a velocidade dos ônibus como série temporal e busca detectar comportamentos anômalos. A motivação é identificar registros inconsistentes, períodos atípicos de operação ou padrões incomuns que possam sinalizar problemas de coleta ou de operação.

### 4.2 Referencial Teórico

O referencial combina análise de séries temporais, detecção de anomalias e preparação de dados em ambiente R. O relatório original menciona o uso do framework Harbinger para detecção de eventos temporais e da Daltoolbox como apoio ao fluxo analítico.

### 4.3 Proposta de Metodologia

O material consolidado mostra um fluxo com duas partes. A primeira organiza a base por linha, veículo e timestamp, transformando as observações em uma tabela temporal por ônibus. A segunda remove valores problemáticos e prepara a série para análise de anomalias por modelo estatístico. A linha 321 e o veículo B28519 aparecem como estudo de caso principal no relatório.

### 4.4 Resultados Parciais

Os resultados parciais sugerem que havia valores constantes e trechos suspeitos que comprometiam a leitura inicial dos dados. A revisão do dataset e a remoção desses comportamentos tornaram a análise mais coerente, permitindo um cenário mais favorável à aplicação do detector de anomalias. O estudo, porém, ainda se encontra em estágio exploratório e depende de refino metodológico.

### 4.5 Códigos Associados

- `codigos/tema-03-anomalias/series.R`
- `codigos/tema-03-anomalias/mobilidade-1.R`

### 4.6 Possíveis Expansões para Artigo Científico

- Definir taxonomias de anomalias operacionais, como parada prolongada, velocidade incompatível e falha de sensor.
- Comparar modelos ARIMA, detecção baseada em decomposição sazonal e métodos modernos de aprendizado de máquina.
- Avaliar o impacto do pré-processamento sobre a taxa de detecção e sobre falsos positivos.

- Expandir o estudo para múltiplas linhas e diferentes dias, investigando recorrência das anomalias.
- Relacionar anomalias detectadas com eventos externos, como chuva, horários de pico e mudanças de operação.

## 5 Tema 4: Classificação de Trajetórias com WiSARD

### 5.1 Introdução

Este tema investiga a classificação de trajetórias de ônibus por linha a partir de redes neurais sem peso, com foco na arquitetura WiSARD. O objetivo é transformar séries de coordenadas geográficas em representações binárias adequadas ao classificador e comparar diferentes estratégias de codificação.

### 5.2 Referencial Teórico

O referencial teórico reúne mobilidade urbana, classificação de trajetórias, binarização de dados geoespaciais, KernelCanvas, grades uniformes, grades baseadas em KD-Tree, codificação por termômetro distributivo e a própria rede WiSARD. O material também discute hiperparâmetros como `addressSize`, `numberOfKernels`, `bitsByKernel` e `activationDegree`.

### 5.3 Proposta de Metodologia

O trabalho foi reorganizado em três blocos metodológicos:

1. Preparação de trajetórias e transformação dos registros de GPS em imagens ou vetores binários.
2. Aplicação de diferentes técnicas de codificação, incluindo KernelCanvas e termômetro distributivo.
3. Treinamento e avaliação do classificador WiSARD para reconhecer linhas de ônibus e medir confiança da classificação.

Essa formulação permite comparar precisão e custo computacional entre diferentes estratégias de representação.

### 5.4 Resultados Parciais

Os resultados parciais indicam melhor desempenho para a combinação grade uniforme + KernelCanvas, com métricas superiores às demais abordagens descritas no relatório original. Em contrapartida, o termômetro distributivo apresentou menor custo computacional na etapa de binarização, o que sugere utilidade em cenários com maior restrição temporal.

### 5.5 Códigos Associados

- `codigos/tema-04-wisard/Codec.py`
- `codigos/tema-04-wisard/wisard/`
- `codigos/tema-04-wisard/KernelCanvas/`

### 5.6 Possíveis Expansões para Artigo Científico

- Realizar comparação sistemática com classificadores tradicionais e profundos, como Random Forest, SVM, CNN e LSTM.
- Investigar novas formas de codificação geoespacial e temporal além de KernelCanvas e termômetro distributivo.
- Estudar sensibilidade dos hiperparâmetros da WiSARD com protocolo experimental mais amplo e reproduzível.
- Avaliar generalização em diferentes subconjuntos de linhas, regiões e períodos temporais.
- Explorar a confiança da classificação como sinal auxiliar para detecção de desvios de rota e comportamento atípico.

## 6 Conclusão

Os quatro trabalhos foram convertidos em temas de pesquisa com uma organização homogênea. A nova estrutura permite enxergar com clareza o que já existe em cada frente: motivação, base teórica, caminho metodológico, estágio atual dos resultados e scripts de apoio. Com isso, o conjunto fica mais adequado para continuidade acadêmica, reaproveitamento de código e refinamento futuro das propostas.